

Modelos lineales

Karina Rojas

- En inferencia estadística hemos estado considerando variables aleatorias iid, implicando por tanto, que tienen un mismo valor esperado, es decir:

$$y_1, y_2 \dots y_n \text{ con } E(y_i) = \mu$$

- No siempre es así, de hecho, muy frecuentemente el valor esperado de una v.a. se puede expresar como una función de una o más variables, por ejemplo:


$$E(y) = \beta_0 + \beta_1 x_1$$

O lo que es lo mismo: $y = \beta_0 + \beta_1 x_1 + \varepsilon$

$\downarrow$ $\downarrow$ $\rightarrow$


Variable dependiente Variable independiente v.a con f_ε
con $\mu_\varepsilon = 0$

Ej., la distancia media que recorre un coche al frenar dependerá de la velocidad que lleve, el nivel medio de PM10 en el aire dependerá de la velocidad del viento....



En la gráfica de dispersión entre las variables independiente y dependiente, vemos que para cada valor de x hay toda una población de posibles valores de y .

La recta $\beta_0 + \beta_1 x_1$ corresponde al valor esperado de la variable dependiente con varianza σ^2



Modelos lineales

- Si sólo nos focalizamos en modelos lineales, consideramos $E(y)$ una función lineal de los parámetros β_i
- Si tenemos dos parámetros, β_1 y β_2 , es un *Modelo de regresión lineal simple*.

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

- Si tenemos más de dos parámetros se trata de un *Modelo de regresión lineal*.

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \varepsilon$$

Definición

Un Modelo estadístico lineal que relaciona una respuesta aleatoria y con un conjunto de variables aleatorias independientes $x_1, \dots, x_k$ es de la forma $y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \varepsilon$, donde los β_i son parámetros desconocidos, ε es una variable aleatoria y las x_i toman valores conocidos.

La existencia de ε en el modelo nos está indicando que no conocemos a la perfección, y varía en torno a $E(y)$ porque no hemos incluido en el modelo todas las variables que determinan y .

- El efecto de estas variables desconocidas se puede aproximar haciendo variar y mediante un comportamiento aleatorio.
- Existen muchos métodos inferenciales para estimar β_i , los que nos proporcionan intervalos de confianza para $E(y)$ para cuando las x_i toman un valor específico. Método que también nos permite estimar un valor de y
- Nos centraremos en uno de ellos, el más conocido y por tanto utilizado, el *Método de mínimos cuadrados*.


Método de mínimos cuadrados

- Asumimos que ε tiene alguna distribución de probabilidad con $E(\varepsilon) = 0$. Si $\hat{\beta}_0$ y $\hat{\beta}_1$ son estimadores de los parámetros β_0 y β_1 , entonces $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ es claramente un estimador de $E(y)$.
- Queremos que las diferencias entre los valores observados y los puntos correspondientes en la recta ajustada sean “pequeñas”.

- El objetivo es minimizar la suma de cuadrados de las desviaciones verticales a partir de la recta ajustada.
- Si $\hat{y}_i$ es el i-ésimo valor estimado cuando $x = x_i$, entonces la desviación del valor observado de y_i a partir de $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ es la diferencia $y_i - \hat{y}_i$.
- La suma de los cuadrados de las desviaciones a minimizar es:

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$


- Gráficamente, ajustamos la recta haciendo pequeñas las desviaciones verticales.



- Si la SSE tiene un mínimo, será para valores de β_0 y β_1 que satisfagan que sus derivadas respecto de $\hat{\beta}_0$ y $\hat{\beta}_1$ sean cero.


- Tales ecuaciones de mínimos cuadrado y sus respectivos cálculos genera tales estimadores por mínimos cuadrado:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2},$$



$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

- Estos estimadores β_0 y β_1 son insesgados y sería relevante conocer su varianza.
- Además, dado que supusimos que $\varepsilon \sim N(0, \sigma^2)$, los estimadores β_0 y β_1 también tendrán una distribución de muestreo Normal.
- Los supuestos de un Modelo de regresión lineal simple son:


$$\begin{aligned} E(\varepsilon) &= 0 \\ \text{Var}(\varepsilon) &= \sigma^2 \end{aligned}$$

Estos supuestos
afectan a y ,
ya que $\varepsilon = y - \hat{y}$

- Como $y = \beta_0 + \beta_1 x_1 + \varepsilon$, entonces, y dado los supuestos sobre ε , la varianza de y también es σ^2 , ya que los otros términos son constantes.
- Respecto del valor esperado y la varianza de $\hat{\beta}_0$ y $\hat{\beta}_1$, podemos comprobar que:

$$E(\hat{\beta}_0) = \beta_0 \quad y \quad E(\hat{\beta}_1) = \beta_1$$

$$\text{Var}(\hat{\beta}_0) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \cdot S_{xx}} \quad y \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$$

- Además, se puede comprobar que $\hat{\beta}_0$ y $\hat{\beta}_1$ están correlacionadas, ya que $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\bar{x} \frac{\sigma^2}{S_{xx}}$

- Una vez que conocemos el valor esperado y la varianza de los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$, nos gustaría saber qué distribución tienen.
- Si un supuesto es que el término de error distribuye como una Normal, estos estimadores también lo harán, así como también la variable respuesta y . Por lo tanto,

$$y \sim \text{Normal}(\beta_0 + \beta_1 x_1, \sigma^2)$$

$$\hat{\beta}_0 \sim \text{Normal}\left(\beta_0, \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \cdot S_{xx}}\right)$$

$$\hat{\beta}_1 \sim \text{Normal}\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

Son funciones
lineales de y

- Es posible comprobar también que:

$$\frac{(n - 2)S^2}{\sigma^2} = \frac{SEE}{\sigma^2}$$

- Por lo que se deduce que tiene una distribución χ^2_{n-2} (se estiman dos parámetros)
- Ahora que conocemos las distribuciones de las estimaciones, haremos algunos contrastes de hipótesis e intervalos de confianza para estimar y evaluar la Recta de regresión lineal simple.

Prueba de hipótesis para β_i

$$H_0 : \beta_i = \beta_{i0}.$$

$$H_a : \begin{cases} \beta_i > \beta_{i0} & (\text{región de rechazo de cola superior}), \\ \beta_i < \beta_{i0} & (\text{región de rechazo de cola inferior}), \\ \beta_i \neq \beta_{i0} & (\text{región de rechazo de dos colas}). \end{cases}$$

$$\text{Estadístico de prueba: } T = \frac{\hat{\beta}_i - \beta_{i0}}{S\sqrt{c_{ii}}}.$$

$$\text{Región de rechazo: } \begin{cases} t > t_\alpha & (\text{alternativa de cola superior}), \\ t < -t_\alpha & (\text{alternativa de cola inferior}), \\ |t| > t_{\alpha/2} & (\text{alternativa de dos colas}), \end{cases}$$

donde

$$c_{00} = \frac{\sum x_i^2}{nS_{xx}} \quad \text{y} \quad c_{11} = \frac{1}{S_{xx}}.$$

Observe que t_α está basada en $(n - 2)$ grados de libertad.

Un intervalo de confianza $100(1 - \alpha)\%$ para β_i

$$\hat{\beta}_i \pm t_{\alpha/2} S\sqrt{c_{ii}},$$

donde

$$c_{00} = \frac{\sum x_i^2}{nS_{xx}} \quad \text{y} \quad c_{11} = \frac{1}{S_{xx}}.$$

- En R, el resumen del modelo entrega:

Coeficientes	Estimación	Error st.	T	Valor-p
Intercepto	$\hat{\beta}_0$	$\sqrt{\frac{S^2 \sum_{i=1}^n x_i^2}{n \cdot S_{xx}}}$	$\frac{\hat{\beta}_0}{St.E(\hat{\beta}_0)}$	$P(t_0 < t_{n-2})$
X	$\hat{\beta}_1$	$\sqrt{\frac{\sigma^2}{S_{xx}}}$	$\frac{\hat{\beta}_1}{St.E(\hat{\beta}_1)}$	$P(t_1 < t_{n-2})$

- Además del coeficiente de determinación R^2 y el valor del estadístico del contraste y valor-p del Modelo completo. Mismo de la tabla Anova (siguiente diapositiva)

- Para evaluar la bondad del ajuste evaluamos qué proporción de la variabilidad de los datos es explicada por el modelo.
- Para esto descomponemos la varianza de esta forma:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$\underbrace{\text{Variabilidad datos}}_{SST} = \underbrace{\text{Variabilidad residuos}}_{SSE} + \underbrace{\text{Variabilidad recta}}_{SSR}$$

- Hacemos un contraste y lo resolvemos con una ANOVA

Anova. Bondad de ajuste

Fuente	gl	SS	MS	estadístico F	p-valor
Regresión	1	SSR	$MSR = \frac{SSR}{1}$	$F = \frac{MSR}{MSE}$	$Pr(F_{1,n-2} > F)$
Error	$n - 2$	SSE	$MSE = \frac{SSE}{n-2}$		
Total	$n - 1$	S_{yy}			

Validación de supuestos del Modelo

- Realizamos contrastes de hipótesis y comprobación visual de gráficas.
- $\varepsilon \sim Normal(E(\varepsilon) = 0, Var(\varepsilon) = \sigma^2)$



$H_0: \varepsilon \sim Normal$
 $H_1: \varepsilon \sim Normal$



- Test Kolmogorov-Smirnov
 - Test Shapiro Wilk
 - Gráfico qplot



$H_0: V(\varepsilon) = \sigma^2 \forall x$
 $H_1: \exists x / V(\varepsilon) \neq \sigma^2$



- Test Levene
 - Gráfico ε
- Gráfico dispersión ε vs $\hat{y}$